

胡明望

意向：多模态大模型 / 智能体算法 | 天津大学电子信息专业博士生

邮箱：humingwang@tju.edu.cn



教育背景

天津大学	人工智能博士研究生	2026.09–2030.06
天津大学	计算机技术硕士研究生	2023.09–2026.06
中国海洋大学	计算机科学与技术本科	2019.09–2023.06

实习经历

华为小艺 | 图像安全风控技术 2024.12–2025.12

- 面向多模态内容安全与图像审核场景，负责涉政隐喻等细粒度风险内容识别与安全对齐评测任务。
- 构建风险样本生成与自动化评测工具，覆盖涉政、涉黄涉暴等风险类型，支撑审核模型迭代优化。
- 涉政隐喻检出率达到 83%，误检率劣化小于 0.3%；生成模型安全对齐后通用能力下降小于 1%。

美团到店研发平台 | 菜品知识图谱构建 2023.05–2024.01

- 面向中餐理解与知识图谱构建任务，开展跨模态食材识别与属性补全研究。
- 构建跨模态食材级数据集 CMIngre，并基于目标检测和图文检索实现食材识别与属性抽取。
- 菜品知识图谱属性准确率达到 96.52%，覆盖率达到 87.01%，商品识别错误率从 20.38% 降低至 2.3%。

项目经历

多智能体驱动的 AIGC 图像侵权检测 2025.08–2025.11

- 面向 AIGC 场景下的图像版权保护需求，研究生成图像与版权图像之间的侵权风险判定问题。
- 设计“摘要-过滤-评判”多智能体框架，引入多角色 Agent 辩论机制进行可解释侵权检测。
- 图像版权侵权检测准确率较传统预训练方法提高 4.33%，F1 Score 提高 19.96%。

科研成果

- Targeted Ensemble Defense against Unauthorized Text-to-Image Identity Customization:** 基于目标扰动的恶意肖像定制通用防御方法，第一作者，*Information Fusion* (SCI 一区), 2025
- FaceOff: Preventing Unauthorized Text-to-Image Identity Customization:** 基于对比增强的恶意肖像定制防御方法，第一作者，*IJCNN* (CCF-C), 2026
- ConNEF: An Encryption Framework for Deep Neural Network IP Protection:** 面向深度神经网络版权保护的加密框架，导一学二，*WWW Short* (CCF-A short), 2025
- Adversarial Attacks and Defenses on Text-to-Image Diffusion Models: A Survey:** 文生图扩散模型对抗攻击与防御综述，第二作者，*Information Fusion* (SCI 一区), 2025
- Toward Chinese Food Understanding: A Cross-Modal Ingredient-Level Benchmark:** 首个跨模态食材级中餐数据集与基准，第三学生作者，*IEEE TMM* (CCF-A), 2024
- 图像处理方法、可读存储介质、程序产品和电子设备:** 基于对抗扰动的图像版权保护技术，发明专利，导一学二，2025

荣誉获奖

天津大学特等学业奖学金 | 天津大学一等学业奖学金 | 天津大学优秀学生干部 (2 次) | 华为智能基座奖学金 | 国家励志奖学金 (2 次) | ASC 世界大学生超级计算机竞赛二等奖